ALZHEIMER HASTALIĞI İÇİN RİSK TAHMİNİ

HAZIRLAYANLAR:
152120221108 ALİ YILMAZ
152120221070 MUHAMMED MEHMET GÖKÇE

SORUN TANIMI

- Alzheimer hastalığı dünya genelinde milyonlarca kişiyi etkileyen ilerleyici bir nörolojik hastalıktır. Bu hastalığın erken teşhisi, tedavi sürecinin etkinliğini artırmak için büyük önem taşır.

- Bu çalışmada, demografik ve sağlıkla ilgili veriler içeren küresel bir Alzheimer veri seti kullanılarak bireylerin Alzheimer hastalığına yakalanma olasılıkları incelenmektedir.

VERİ SETİNİN İÇERİĞİ

Country	Age	Gender	Education Level	BMI	Physical Activity	Smoking Status	Alcohol Consumption	Diabetes	Hypertension
Spain	90	Male	1	33.0	Medium	Never	Occasionally	No	No
Argentina	72	Male	7	29.9	Medium	Former	Never	No	No
South Africa	86	Female	19	22.9	High	Current	Occasionally	No	Yes
China	53	Male	17	31.2	Low	Never	Regularly	Yes	No
Sweden	58	Female	3	30.0	High	Former	Never	Yes	No

VERİ SETİNDEKİ DEĞERLER VE AÇIKLAMALARI

Country: Kişinin yaşadığı ülkeyi belirtir.

Age: Bireyin yaşı (50-94).

Gender: Bireyin cinsiyeti (Male/Female).

Education Level: Bireyin eğitim seviyesi (0-19).

BMI (Body Mass Index): Kişinin vücut kitle indeksi (kg/m²) (18.5-35).

Physical Activity Level: Bireyin düzenli fiziksel aktivite yapıp yapmadığını belirtir (Low - Medium - High).

Smoking Status: Bireyin sigara kullanıp kullanmadığını belirtir (Never - Former - Current).

Alcohol Consumption: Bireyin alkol tüketme durumu (Never - Occasionally - Regularly).

Diabetes: Bireyin diyabet hastası olup olmadığı (Yes/No).

Hypertension: Bireyin hipertansiyon hastası olup olmadığı (Yes/No).

VERİ SETİNDEKİ MUHTEMEL EKSİKLİKLER

1. Family History (Ailede Alzheimer Öyküsü):
Veri setinde bireylerin ailesinde Alzheimer hastalığı geçmişine dair bilgi bulunmamaktadır. Oysa bu bilgi, genetik yatkınlığı doğrudan yansıttığı için hastalık riskinin değerlendirilmesinde kritik bir rol oynamaktadır.

2. APOE4 Gen Durumu:
Alzheimer ile güçlü ilişkisi bilimsel olarak kanıtlanmış APOE4 geninin taşıyıcılığına ilişkin herhangi bir veri yer almamaktadır. Bu genin varlığı, bireyin genetik riskini belirlemede önemli olup, özellikle Bayes Teoremi gibi koşullu olasılık analizleri için büyük katkı sağlar.

3. Sleep Duration / Sleep Quality (Uyku Süresi ve Kalitesi):
Bireylerin uyku düzeni ya da uyku kalitesiyle ilgili herhangi bir bilgiye yer verilmemiştir. Oysa kaliteli ve yeterli uyku, beyin sağlığı açısından önemli bir faktördür ve Alzheimer riskini azaltmada etkili olduğu bilinmektedir.

4. Depression / Social Isolation (Depresyon ve Sosyal İzolasyon):
Veri setinde bireylerin psikolojik durumları veya sosyal etkileşim düzeylerine dair herhangi bir kayıt yer almamaktadır. Oysa depresyon, sosyal izolasyon ve yalnızlık gibi durumların, Alzheimer gelişimi üzerinde önemli bir çevresel ve psikolojik etkisi olduğu literatürde sıkça vurgulanmaktadır.

VERİ SETİNDEKİ KULLANMAYACAĞIMIZ VERİLER

Country (Ülke):
Veri setinde bireylerin yaşadıkları ülke bilgisi yer alsa da, bu değişken doğrudan Alzheimer riskiyle bireysel düzeyde ilişkilendirilemeyebilir. Ülke bazlı karşılaştırmalar, coğrafi analizler yapılmadığı sürece modelleme açısından anlamlı sonuçlar vermeyebilir. Ayrıca çok sayıda ülkenin yer alması, modelin gereksiz şekilde karmaşıklaşmasına neden olabilir. Alternatif olarak, ülkeler gelişmiş/gelişmekte olan şeklinde gruplandırılarak daha anlamlı hale getirilebilir.

Gender (Cinsiyet):
Cinsiyet, Alzheimer hastalığında belirli ölçüde etkili olabilir; örneğin kadınlarda hastalık daha sık görülmektedir. Ancak bu fark genellikle kadınların daha uzun yaşamasından kaynaklanmakta ve hastalığın cinsiyete özel biyolojik bir farklılıkla değil, yaşam süresiyle ilişkili olarak ortaya çıkmaktadır. Bu nedenle, modelde belirleyici bir değişken olarak öne çıkması beklenmemektedir.

AKADEMİK ÇALIŞMALAR

Machine Learning Approaches for Prediction of Alzheimer's Disease

İşlemler:

- 2.149 hastaya ait 35 özellik içeren bir veri seti kullanılmıştır.
- Farklı makine öğrenmesi algoritmaları ile Alzheimer hastalığı tahmini gerçekleştirilmiştir.
- Veriler analiz öncesi temizlenmiş ve uygun formatta modele hazırlanmıştır.

Kullanılan Algoritmalar:

- XGBoost, Karar Ağaçları, Destek Vektör Makineleri (SVM), Rastgele Orman (Random Forest) ve diğer klasik sınıflandırıcılar test edilmiştir.
- Algoritmalar karşılaştırmalı olarak değerlendirilmiştir.

Sonuçlar:

- XGBoost algoritması %95,35 doğruluk oranı ile en iyi sonucu vermiştir.
- Veri setinde bulunan demografik ve klinik değişkenlerin, Alzheimer risk tahmini açısından anlamlı olduğu tespit edilmiştir.

Kaynak: Journal of Artificial Intelligence and Data Science, 2024 – Kadriye Filiz Balbal

AKADEMİK ÇALIŞMALAR

A Machine Learning Model for Alzheimer's Disease Prediction

İşlemler:

- OASIS veri seti kullanılarak Alzheimer hastalığının tahmini amaçlanmıştır.
- Veri dengesizliği problemi, SMOTE yöntemiyle giderilmiş; model eğitimi öncesi ön işleme adımları uygulanmıştır.

Kullanılan Algoritmalar:

- Rastgele Orman (Random Forest) algoritması kullanılmıştır.
- Modelin başarım oranı, eğitim ve test aşamalarında ayrı ayrı değerlendirilmiştir.

Sonuçlar:

- Model %94,03 doğruluk oranına ulaşmıştır.
- OASIS veri setindeki özellikler, Alzheimer riskinin belirlenmesinde etkili bulunmuştur.

Kaynak: ResearchGate, 2023 – Rani et al.

KULLANILACAK YÖNTEM VE TEKNİKLER

1. Veri Ön İşleme

Eksik Veri İşleme: Veri setinde eksik veya boş hücreler tespit edilip temizlenecek. Bu işlemde ortalama, medyan gibi istatistiksel yöntemler veya uygun durumlarda satır/sütun çıkarma uygulanabilir.

Öznitelik Seçimi (Feature Selection): Alzheimer riskini en çok etkileyen faktörleri belirlemek amacıyla Random Forest gibi algoritmalarla değişken önem sıralaması yapılacaktır.

Veri Dönüştürme ve Normalizasyon: Kategorik veriler (örneğin: fiziksel aktivite düzeyi, sigara durumu) sayısal değerlere dönüştürülecek. Ayrıca bazı algoritmalar için gerekli olan normalizasyon işlemleri (örneğin: yaş, BMI için) yapılacaktır.

2. Makine Öğrenmesi Yöntemleri

Destek Vektör Makineleri (SVM): Veri setindeki özellikleri kullanarak Alzheimer hastalığını sınıflandırmak için sınırları belirleyen bir algoritmadır. Özellikle çok boyutlu verilerde başarılıdır.

Karar Ağaçları ve Rastgele Ormanlar (Random Forest): Bu algoritmalar, risk faktörleri arasındaki ilişkiyi öğrenerek hastalık tahmini yapar. Rastgele ormanlar, daha yüksek doğruluk ve daha düşük hata oranı sağlar.

K-En Yakın Komşu (k-NN): Yeni bir bireyin verileri, eğitim verisindeki en benzer bireylerle karşılaştırılarak Alzheimer riski tahmin edilir.

KULLANILACAK YÖNTEM VE TEKNİKLER

3. Model Değerlendirmesi

Çapraz Doğrulama (Cross-Validation): Modellerin güvenilirliğini test etmek için k-fold çapraz doğrulama kullanılacaktır. Bu, modelin farklı veri bölümlerindeki performansını test ederek genelleme yeteneğini ölçer.

Performans Metrikleri: Modelin başarı düzeyi; doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1-skore gibi metriklerle değerlendirilecektir. Bu ölçütler, modelin Alzheimer hastalığını tahmin etmedeki etkinliğini gösterir.

HEDEFLER

1. Alzheimer'ın Erken Teşhisi İçin Demografik ve Sağlık Verilerinin Kullanımını Analiz Etmek

Demografik bilgiler (yaş, cinsiyet, eğitim düzeyi) ve bireylerin sağlık geçmişi (hipertansiyon, diyabet vb.) kullanılarak Alzheimer hastalığının erken teşhisine katkı sağlayabilecek örüntüleri ortaya çıkarmak. Veri analizi ile, bu faktörlerin erken evre risk tahmini üzerindeki etkisini değerlendirmek.

2. Yaşam Tarzı ve Kronik Hastalıklar ile Alzheimer Riski Arasındaki İlişkiyi İncelemek

Fiziksel aktivite düzeyi, sigara/alkol kullanımı, uyku süresi gibi yaşam tarzı faktörlerinin Alzheimer riski ile olan ilişkisini analiz etmek. Hangi faktörlerin hastalığa yatkınlık ile daha güçlü bir bağlantı gösterdiğini istatistiksel olarak ortaya koymak.

3. Alzheimer'a Yatkın Bireyleri Doğru Şekilde Sınıflandırmak

Makine öğrenmesi algoritmalarını kullanarak, veri setindeki bireyleri risk düzeylerine göre sınıflandırmak. Bu sınıflandırma sayesinde yüksek riskli bireyleri belirleyip, erken teşhis ve önleyici sağlık uygulamalarına yönlendirme potansiyelini değerlendirmek.

4. Alzheimer Tanısında Hız ve Doğruluk Arasındaki Dengeyi Sağlamak

Geliştirilen modellerin tanı sürecinde hem doğru hem de hızlı sonuç verebilmesini hedeflemek. Model performans metrikleri (doğruluk, precision, recall, F1-score) kullanılarak bu dengeyi test etmek ve iyileştirme önerileri sunmak.

KAYNAKÇA

Balbal, K. F. (2024). Machine Learning Approaches for Prediction of Alzheimer’s Disease. Journal of Artificial Intelligence and Data Science. https://dergipark.org.tr/en/pub/jaida/issue/89048/1599026

Rani, A. et al. (2023). A Machine Learning Model for Alzheimer's Disease Prediction. ResearchGate. https://www.researchgate.net/publication/379118216

Kaggle Dataset – Alzheimer's Prediction Dataset (Global) Ankush Panday (2022). https://www.kaggle.com/datasets/ankushpanday1/alzheimers-prediction-dataset-global/data